

# ESTIMAÇÃO PONTUAL DA MÉDIA DA VARIÁVEL RESPOSTA

Dados os estimadores  $\hat{\beta}_0$  e  $\hat{\beta}_1$  dos parâmetros da função de regressão:

$$E(Y) = \beta_0 + \beta_1 X$$

A função de regressão estimada é dada por:

$$\hat{Y} = E(\hat{Y}) = \hat{\beta}_0 + \hat{\beta}_1 X,$$

em que  $\hat{Y}$  é o valor estimado da média da distribuição de  $Y$ , dado a informação da variável explicativa  $X$ .

# ESTIMAÇÃO PONTUAL DA MÉDIA DA VARIÁVEL RESPOSTA

Pode ser mostrado como uma extensão do **Teorema de Gauss Markov** que:

- $\hat{Y}$  é um estimador não viesado de  $E(Y)$ ,
- com variância mínima na classe de estimadores lineares não viesados.

Para as observações da amostra, o valor estimado para  $i$ -ésima observação é dado por:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

em que  $i = 1, \dots, n$ .

# RESÍDUO DO MODELO

- O  $i$ -ésimo **resíduo** é a diferença entre o valor observado  $Y_i$  e seu correspondente valor estimado  $\hat{Y}_i$ .
- O resíduo é denotado por  $e_i$  e é definido por:

$$e_i = Y_i - \hat{Y}_i.$$

O resíduo é representado por:

$$e_i = Y_i - (\hat{\beta}_0 + \hat{\beta}_1 X) = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X.$$

- Os resíduos são **importantes** para estudar se o modelo de regressão é apropriado para analisar os dados em estudo.

# ATENÇÃO!!!

É importante distinguir entre:

- Erro do modelo:

$$\varepsilon_i = Y_i - E(Y_i),$$

e

- Resíduo:

$$e_i = Y_i - \hat{Y}_i.$$

# PROPRIEDADES DA RETA DE REGRESSÃO ESTIMADA

1. A soma dos resíduos do modelo de regressão é **ZERO**:

$$\sum_{i=1}^n (Y_i - \hat{Y}_i) = \sum_{i=1}^n e_i = 0$$

2. A soma do quadrado do resíduo,  $\sum_{i=1}^n e_i^2$ , é um mínimo.  
 $\implies$  Pressuposto a ser satisfeito na dedução dos estimadores de mínimos quadrados.

# PROPRIEDADES DA RETA DE REGRESSÃO ESTIMADA

3. A soma dos valores observados  $Y_i$ , é igual a soma dos valores estimados  $\hat{Y}_i$ :

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n \hat{Y}_i$$

4. A soma ponderada dos resíduos é **ZERO** quando o resíduo da  $i$ -ésima observação é ponderado pelo nível da variável explicativa da  $i$ -ésima observação:

$$\sum_{i=1}^n X_i e_i = 0$$

# PROPRIEDADES DA RETA DE REGRESSÃO ESTIMADA

5. A soma ponderada dos resíduos é **ZERO** quando o resíduo da  $i$ -ésima observação é ponderado pelo valor estimado da variável resposta da  $i$ -ésima observação:

$$\sum_{i=1}^n \hat{Y}_i e_i = 0$$

6. A reta de regressão sempre passa através do ponto  $(\bar{X}, \bar{Y})$ .

# ESTIMAÇÃO DA VARIÂNCIA DO ERRO

A variância  $\sigma^2$  do erro  $\varepsilon_i$  do modelo de regressão precisa ser estimada por alguns motivos:

- $\text{Var}(Y_i) = \text{Var}(\varepsilon_i) = \sigma^2$  - estimar  $\sigma^2$  para obter uma indicação da variabilidade da distribuição de probabilidade de  $Y$ ,
- Para construir Intervalos de Confiança e Testes de Hipóteses dos parâmetros  $\beta_0$  e  $\beta_1$ ,
- Para fazer predição de  $Y$ .



# REVISANDO

Na amostragem de uma população, a variância  $\sigma^2$ , é estimada pela variância da amostra  $s^2$ :

$$s^2 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1},$$

em que:

- $Y_i - \bar{Y}$  - são os desvios de  $Y_i$  em torno da média estimada,
- $\sum_{i=1}^n (Y_i - \bar{Y})^2$  - Soma de quadrados,
- $n - 1$  graus de liberdade.

# ESTIMAÇÃO DA VARIÂNCIA DO ERRO

Ao considerar o modelo de regressão linear simples, o desvio de uma observação  $Y_i$  deve ser calculado em torno da sua própria média estimada  $E(\hat{Y}_i) = \hat{Y}_i$ . Esses desvios são os resíduos:

$$e_i = Y_i - \hat{Y}_i.$$

Dessa forma, o estimador da variância  $\sigma^2$  do erro  $\varepsilon_i$  é:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - 2} = \frac{\sum_{i=1}^n e_i^2}{n - 2} = \frac{\text{SQRes}}{n - 2} = \text{MSRes}, \quad (1)$$

- $\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$  - Soma de quadrados do resíduo - SQRes,
- $n - 2$  graus de liberdade,
- MSRes - quadrado médio do resíduo
- é um estimador não viesado de  $\sigma^2$  para o modelo de regressão.

# ESTIMAÇÃO DA VARIÂNCIA DO ERRO

Consequentemente, um estimador para  $\sigma$  é:

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\text{MSRes.}}$$

## VARIÂNCIA DE $\hat{\beta}_1$ E $\hat{\beta}_0$

Pode-se encontrar a variância de  $\hat{\beta}_1$  e  $\hat{\beta}_0$ , respectivamente, por:

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\sigma^2}{SQ_{XX}},$$

e

$$Var(\hat{\beta}_0) = \sigma^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right] = \sigma^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{SQ_{XX}} \right].$$

# ESTIMADOR DA VARIÂNCIA DOS PARÂMETROS

Ao considerar o estimador da variância  $\sigma^2$  definido em (1), temos:

- Estimador da variância de  $\hat{\beta}_1$ :

$$\text{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\hat{\sigma}^2}{SQ_{XX}},$$

- Estimador da variância de  $\hat{\beta}_0$ :

$$\text{Var}(\hat{\beta}_0) = \hat{\sigma}^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right] = \hat{\sigma}^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{SQ_{XX}} \right].$$

# DISTRIBUIÇÃO AMOSTRAL

Ao considerar as hipóteses do modelo:

- $E(\varepsilon_i)=0$
- $\text{Var}(\varepsilon_i)=\sigma^2$
- $\text{Cov}(\varepsilon_i, \varepsilon_j)$  para todo  $i, j; i \neq j$
- $\varepsilon_i$  são independentes e identicamente distribuídos:  $N(0, \sigma^2)$

A distribuição de probabilidade de  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  é:  
 $N(\beta_0 + \beta_1 X_i, \sigma^2)$ .

# DISTRIBUIÇÃO AMOSTRAL DE $\beta_1$

Como  $\hat{\beta}_1$  é uma combinação linear das observações  $Y_i$  (variáveis normais independentes):

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right).$$

A estatística padronizada:

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\text{Var}(\hat{\beta}_1)}} = \frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}},$$

tem distribuição Normal padrão,  $N(0,1)$ .

# DISTRIBUIÇÃO AMOSTRAL DE $\beta_1$

Como é preciso estimar  $\text{Var}(\hat{\beta}_1)$  por  $\text{Var}(\hat{\hat{\beta}}_1)$ , a estatística:

$$\frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\text{Var}(\hat{\hat{\beta}}_1)}} = \frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}},$$

tem distribuição  $t$ -Student( $n-2$ ) para o modelo definido.



## INTERVALO DE CONFIANÇA PARA $\beta_1$

Ao considerar o resultado do slide anterior, escrevemos a seguinte probabilidade:

$$P\left(t_{(\alpha/2;n-2)} \leq \frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\text{Var}(\hat{\beta}_1)}} \leq t_{(1-\alpha/2;n-2)}\right) = 1 - \alpha$$

Devido a simetria da distribuição  $t$ -Student, temos que:

$$t_{(\alpha/2;n-2)} = -t_{(1-\alpha/2;n-2)},$$

logo:

$$P\left(-t_{(1-\alpha/2;n-2)} \leq \frac{(\hat{\beta}_1 - \beta_1)}{\sqrt{\text{Var}(\hat{\beta}_1)}} \leq t_{(1-\alpha/2;n-2)}\right) = 1 - \alpha$$

# INTERVALO DE CONFIANÇA PARA $\beta_1$

Dessa forma, um Intervalo de Confiança  $(1 - \alpha)$  para o parâmetro  $\beta_1$  do modelo de regressão linear simples é dado por:

$$IC(\beta_1, (1 - \alpha)) = \left( \hat{\beta}_1 - t_{(1-\alpha/2; n-2)} \sqrt{\text{Var}(\hat{\beta}_1)}; \hat{\beta}_1 + t_{(1-\alpha/2; n-2)} \sqrt{\text{Var}(\hat{\beta}_1)} \right),$$

ao substituir o intervalo pelo estimador da variância de  $\hat{\beta}_1$ , o intervalo é definido por:

$$IC(\beta_1, (1 - \alpha)) = \left( \hat{\beta}_1 - t_{(1-\alpha/2; n-2)} \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}; \hat{\beta}_1 + t_{(1-\alpha/2; n-2)} \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} \right)$$

# TESTE DE HIPÓTESE PARA $\beta_1$

- Suponha que desejamos testar a hipótese de que o coeficiente angular é igual a uma constante,  $\beta_{10}$ . As hipóteses são:

$$H_0 : \beta_1 = \beta_{10}$$

$$H_1 : \beta_1 \neq \beta_{10}$$

- Supondo  $H_0$  verdadeira, a estatística do teste é dada por:

$$t = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\text{Var}(\hat{\beta}_1)}},$$

e tem distribuição  $t$ -Student com  $(n-2)$  graus de liberdade.

# TESTE DE HIPÓTESE PARA $\beta_1$

- Um particular teste de hipótese para o coeficiente angular:

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

Ou seja,

$H_0$  : ausência de regressão

$H_1$  : existe regressão

- Supondo  $H_0$  verdadeira, a estatística do teste é dada por:

$$t = \frac{\hat{\beta}_1 - 0}{\sqrt{\text{Var}(\hat{\beta}_1)}},$$

e tem distribuição  $t$ -Student com  $(n-2)$  graus de liberdade.

# TESTE DE HIPÓTESE PARA $\beta_1$

- Fixando o nível de significância,  $\alpha$ , define-se a região crítica ou de rejeição do teste,
- Seja  $t$  o valor da estatística do teste para a amostra obtida:
  - Se  $t \in (-t_{1-\alpha/2}, t_{1-\alpha/2})$ , então não há evidências para rejeitar  $H_0$ ,
  - Se  $t$  não pertence  $(-t_{1-\alpha/2}, t_{1-\alpha/2})$ , então há evidências para rejeitar  $H_0$

# DISTRIBUIÇÃO AMOSTRAL DE $\beta_0$

Como  $\hat{\beta}_0$  é uma combinação linear das observações  $Y_i$  (variáveis normais independentes):

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2 \cdot \left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right]\right).$$

A estatística padronizada:

$$\frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\text{Var}(\hat{\beta}_0)}} = \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\sigma^2 \cdot \left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right]}},$$

tem distribuição Normal padrão,  $N(0,1)$ .

# DISTRIBUIÇÃO AMOSTRAL DE $\beta_0$

Como é preciso estimar  $\text{Var}(\hat{\beta}_0)$  por  $\text{Var}(\hat{\beta}_0)$ , a estatística:

$$\frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\text{Var}(\hat{\beta}_0)}} = \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\hat{\sigma}^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}},$$

tem distribuição  $t$ -Student( $n-2$ ) para o modelo definido.

## INTERVALO DE CONFIANÇA PARA $\beta_0$

Ao considerar o resultado do slide anterior, escrevemos a seguinte probabilidade:

$$P\left(t_{(\alpha/2;n-2)} \leq \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\text{Var}(\hat{\beta}_0)}} \leq t_{(1-\alpha/2;n-2)}\right) = 1 - \alpha$$

Devido a simetria da distribuição  $t$ -Student, temos que:

$$t_{(\alpha/2;n-2)} = -t_{(1-\alpha/2;n-2)},$$

logo:

$$P\left(-t_{(1-\alpha/2;n-2)} \leq \frac{(\hat{\beta}_0 - \beta_0)}{\sqrt{\text{Var}(\hat{\beta}_0)}} \leq t_{(1-\alpha/2;n-2)}\right) = 1 - \alpha$$



## INTERVALO DE CONFIANÇA PARA $\beta_0$

Dessa forma, um Intervalo de Confiança  $(1 - \alpha)$  para o parâmetro  $\beta_0$  do modelo de regressão linear simples é dado por:

$$IC(\beta_0, (1 - \alpha)) = \left( \hat{\beta}_0 - t_{(1-\alpha/2; n-2)} \sqrt{\text{Var}(\hat{\beta}_0)}; \hat{\beta}_0 + t_{(1-\alpha/2; n-2)} \sqrt{\text{Var}(\hat{\beta}_0)} \right),$$

ao substituir o intervalo pelo estimador da variância de  $\hat{\beta}_0$ , o intervalo é definido por:

$$IC(\beta_0, (1 - \alpha)) = \left( \hat{\beta}_0 - t_{(1-\alpha/2; n-2)} \sqrt{\hat{\sigma}^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}; \hat{\beta}_0 + t_{(1-\alpha/2; n-2)} \sqrt{\hat{\sigma}^2 \cdot \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]} \right)$$

# TESTE DE HIPÓTESE PARA $\beta_0$

- Suponha que desejamos testar a hipótese de que o intercepto é igual a uma constante,  $\beta_{00}$ . As hipóteses são:

$$H_0 : \beta_0 = \beta_{00}$$

$$H_1 : \beta_0 \neq \beta_{00}$$

- Supondo  $H_0$  verdadeira, a estatística do teste é dada por:

$$t = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{\text{Var}(\hat{\beta}_0)}},$$

e tem distribuição  $t$ -Student com  $(n-2)$  graus de liberdade.

# DISTRIBUIÇÃO AMOSTRAL DE $\hat{Y}_0 = E(\hat{Y}_0)$

- Para cada  $X_0$ , nível da variável explicativa,  $X$ , desejamos estimar a resposta média  
 $E(Y_0) = E(Y_0|X = X_0) = \beta_0 + \beta_1 X_0$ ,
- $X_0$  pode ser:
  - um particular valor que ocorreu na amostra;
  - qualquer valor da variável explicativa,  $X$ , que esteja dentro do alcance do modelo.
- Um estimador pontual do valor esperado de  $Y$  já foi definido anteriormente por:

$$\hat{Y} = E(\hat{Y}) = \hat{\beta}_0 + \hat{\beta}_1 X$$

- Ao considerar um particular valor da variável explicativa,  $X_0$ , o estimador do valor esperado de  $Y_0$  é:

$$\hat{Y}_0 = E(\hat{Y}_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0 \quad (2)$$

# DISTRIBUIÇÃO AMOSTRAL DE $\hat{Y}_0 = E(\hat{Y}_0)$

- A distribuição amostral de  $\hat{Y}_0$ , refere-se a diferentes valores de  $\hat{Y}_0$  que seriam obtidos se amostras repetidas são selecionadas, cada uma mantendo os níveis da variável regressora  $X$  constante, e calculando  $\hat{Y}_0$  para cada amostra.
- Para o modelo de regressão linear simples, a distribuição amostral de  $\hat{Y}_0$  é Normal com média e variância dadas por:
- $E(\hat{Y}_0) = E(E(\hat{Y}_0)) = E(Y_0)$

e

- $$\text{Var}(\hat{Y}_0) = \sigma^2 \left[ \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right].$$

# DISTRIBUIÇÃO AMOSTRAL DE $\hat{Y}_0 = E(\hat{Y}_0)$

- Ao considerar o estimador da variância  $\sigma^2$ , a variância de  $\text{Var}(\hat{Y}_0)$  estimada é dada por:

$$\text{Var}(\hat{Y}_0) = \hat{\sigma}^2 \left[ \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

- Observações:
  - A variabilidade de  $\hat{Y}_0$  é afetada pela distância entre  $X_0$  e  $\bar{X}$ ,
  - Quando  $X_0 = 0$ , a variância de  $\hat{Y}_0$  reduz a variância de  $\hat{\beta}_0$  e a estimativa da variância de  $\hat{Y}_0$  reduz a  $\text{Var}(\hat{\beta}_0)$ .

# DISTRIBUIÇÃO AMOSTRAL DE $\hat{Y}_0 = E(\hat{Y}_0)$

- Ao considerar a distribuição de  $\hat{Y}_0$ , a estatística:

$$\frac{\hat{Y}_0 - E(Y_0)}{\text{Var}(\hat{Y})} \quad (3)$$

tem distribuição  $t$ -Studente com  $(n - 2)$  graus de liberdade para o modelo de regressão linear simples.

# INTERVALO DE CONFIANÇA

- Ao considerar a distribuição de  $\hat{Y}_0$ , um Intervalo de Confiança  $(1 - \alpha)$  para  $E(Y_0)$  é dado por:

$$IC(E(Y_0); 1 - \alpha) = \left( \hat{Y}_0 - t_{(1-\alpha/2; n-2)} \hat{\sigma} \sqrt{A}; \hat{Y}_0 + t_{(1-\alpha/2; n-2)} \hat{\sigma} \sqrt{A} \right)$$

$$\text{em que } A = \left[ \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right].$$